

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ
ВЫСШЕГО ПРОФЕССИОНАЛЬНОГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет информатики, математики и компьютерных наук
Программа подготовки бакалавров по направлению
01.03.02 Прикладная математика и информатика

Тюрин Владислав Николаевич

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Построение графа знаний на основе пользовательских данных с
возможностью экспорта в Obsidian

Научный руководитель
Приглашенный преподаватель

В. М. Кочеганов

Нижний Новгород, 2026

ОГЛАВЛЕНИЕ

Содержание

Введение	4
1. Теоретические основы и обзор предметной области	8
1.1. Системы управления персональными знаниями	8
1.2. Технологии поиска и обработки естественного языка в системах RAG	11
1.3. Анализ существующих решений для построения графов знаний	13
1.4. Методология оценки качества	19
2. Разработка алгоритмов	26
2.1. Архитектура алгоритма построения графа знаний	26
2.2. Алгоритм GraphRAG	34
3. Сбор и подготовка данных	38
3.1. Поиск данных	38
3.2. Создание валидационного датасета	39
3.2.1 Алгоритм генерации связей	41
3.2.2 Алгоритм извлечения контекста	44
3.2.3 Алгоритм LLM-классификации отношений	44
4. Эксперименты	46
4.1. Параметры воспроизводимости	46
4.2. Оценка конвейера построения графа знаний	46
4.2.1 Извлечение кандидатных пар	46
4.2.2 Классификация типов связей	50
4.3. Сравнение сгенерированных ссылок с эталонными	52
4.4. Оценка конвейера GraphRAG	53
4.4.1 Анализ референсных решений	54
4.4.2 Сравнение собственных алгоритмов с аналогами	55

4.4.3 Влияние промпта и языковой модели	57
4.4.4 Анализ влияния графа.	60
4.5. Выводы и ограничения исследования	61
5. Заключение	63
6. Список литературы	64
7. Приложение А	68
7.1. Репозиторий с кодом:	68
7.2. Визуализации подкорпусов датасета	69

АННОТАЦИЯ

ABSTRACT

ВВЕДЕНИЕ

В эпоху информационной перегрузки возможность эффективно управлять данными стала особенно важной. Классических способов работы с информацией, таких как ведение заметок, уже недостаточно, особенно для специалистов регулярно работающих с огромными массивами данных из разных областей [1]. В качестве решения были разработаны специализированные системы для управления знаниями, например, Obsidian [2]. Они берут на себя роль «второго мозга» [3], освобождая пользователей от хранения всей информации в голове и упрощая работу с ней.

Современные системы управления знаниями поддерживают генерацию с дополненной выборкой (Retrieval-Augmented Generation, RAG) [4]. Большинство RAG-систем используют гибридный поиск (комбинацию лексического [5] и семантического [6]). Такой подход имеет несколько слабостей: лексический поиск не умеет искать синонимы, а семантический может упустить релевантные данные из-за большой разницы в векторных представлениях (эмбедингах) [7].

Более продвинутой стратегией поиска является использование графов знаний (ГЗ) [8], которые соединяют семантически связанные сущности. Каждая связь имеет направление и тип, отражающие семантическое отношение между сущностями. Это открывает доступ к многошаговому поиску, что решает проблемы гибридного поиска и позволяет увеличить полноту результатов.

Несмотря на преимущества ГЗ, их построение и поддержание требуют колоссальных трудозатрат. По мере роста базы знаний возникает «узкое горлышко»: пользователям недостаточно когнитивных ресурсов и времени на анализ и связывание заметок, из-за чего дальнейшее развитие базы становится невозможным.

Существующие на данный момент решения (графовые базы данных корпоративного уровня [9, 10] или облачные приложения [11]) имеют критические недостатки. Базы данных требуют дорогостоящей инфраструктуры и чрезмерно зависят от больших языковых моделей (LLM) [12], что приводит к большим издержкам и созданию бессмысленных связей [13]. Облачные решения, несмотря на их удобство для повседневного использования, создают риск утечки данных и насильно привязывают пользователей к экосистеме.

Цель работы – разработка автоматизированного алгоритма для построения графов знаний с помощью семантического связывания заметок в экосистеме Obsidian, а также сравнение разработанного решения с существующими аналогами в сценариях использования RAG.

Для достижения поставленной цели были сформулированы следующие задачи:

1. Провести анализ существующих решений для построения графов знаний для выявления их ограничений и функциональных особенностей.
2. Разработать алгоритм автоматического поиска и типизации связей, включающий: извлечение содержимого Markdown-файлов; гибридный поиск кандидатов; классификацию связей; сохранение найденных отношений, поддерживающее инкрементальные обновления.
3. Создать систему валидации и репрезентативный аннотированный набор данных для объективной оценки качества работы алгоритма и сравнения с аналогами.
4. Провести итеративное улучшение решения, состоящее из экспериментов с различными моделями, гиперпараметрами и методами фильтрации связей, для повышения точности и ее вычислительной эффективности системы.

Объект исследования — процессы поиска, структурирования и извлечения информации в системах управления знаниями. Предмет исследования — методы

и алгоритмы автоматического семантического связывания текстовых данных для построения ГЗ.

Использованные в работы методы исследования включают: методы обработки естественного языка (NLP), методы машинного обучения (LLM и модели эмбедингов), методы информационного поиска (BM25, семантический поиск), элементы теории графов, а также методы системного анализа и эмпирического тестирования.

Научная новизна данной работы заключается в создании автоматизированного алгоритма семантического связывания Markdown-заметок, комбинирующего гибридный поиск, модели машинного обучения (Cross Encoder [14] и LLM), сохранение состояния работы и инкрементальных обновлений ГЗ. В отличие от существующих решений, разработанный алгоритм оптимизирован для работы локально при ограниченных вычислительных мощностях, обеспечивая полный суверенитет данных.

Теоретическая значимость работы состоит в развитии подходов автоматизированного извлечения семантических отношений из неструктурированных текстовых данных, адаптации алгоритма GraphRAG для работы в экосистеме Obsidian, в том числе с типизированными ссылками, а также оценке реализованных решений.

Достоверность полученных результатов подтверждается использованием стандартизированных подходов к оценке качества информационного поиска и алгоритмов RAG, использованием в ручную размеченного валидационного набора данных для оценки, а также согласованность полученных практических результатов с теорией.

Алгоритм, разрабатываемый в данной работе, ориентирован на продвинутых пользователей баз знаний, для которых важны суверенность данных, возможность работы алгоритма локально или при ограниченных вычислительных мощностях, а также поддержка эффективного обновления ГЗ. Все вышеперечисленные особенности, реализованные в рамках одной

системы, не имеют аналогов, и, следовательно, обладают высокой практической ценностью.

ТЕОРЕТИЧЕСКИЕ ОСНОВЫ И ОБЗОР ПРЕДМЕТНОЙ ОБЛАСТИ

1.1 Системы управления персональными знаниями

В эру информационной перегрузки необходимо эффективно и умело управлять данными. Традиционные методы хранения и обработки информации, такие как рукописные заметки или их цифровые аналоги, хороши для повседневного использования, но не способны обеспечить необходимую функциональность и эффективность работы для людей с огромными массивами информации. Возрастающая актуальность этой проблемы спровоцировала развитие специальных систем для управления персональными знаниями (Personal Knowledge Management, PKM).

В основу PKM-систем легла концепция «Второго мозга» (Second Brain), популяризированная исследователем Тиаго Форте [3]. В ней хранение и организация информации полностью перекладывается на внешние носители, что позволяет освободить когнитивные ресурсы человека.

Человеческое мышление ассоциативно, в нем одна концепция может принадлежать разным областям знания. Иерархические структуры не обладают достаточной гибкостью, так как требуют однозначной категоризации, что противоречит устройству человеческого мышления. Им на смену пришли сетевые структуры, наподобие Zettelkasten («картотечный ящик»), [1], разработанный социологом Никласом Луманом. Этот подход заключается в хранении небольших атомарных заметок, связанных друг с другом. Связи в нем представляют основную ценность: информация, хранящаяся в заметках, не абстрагирована, а встроена в общий пласт знаний, что ускоряет поиск и позволяет делать сложные, на первый взгляд неочевидные умозаключения.

Популярным представителем современной реализации подхода Zettelkasten является программа Obsidian. В ней заметки хранятся в виде файлов формата Markdown. Заметки поддерживают двунаправленное связывание путем упоминания заметки в тексте (формат `[[wikilink]]`). Кроме того, в заметках

можно добавлять специальные пометки, тэги, по которым можно осуществлять быструю фильтрацию и поиск.

Такая архитектура облегчает организацию данных, а также обеспечивает их суверенитет, поскольку пользователь сам выбирает место их хранения.

В основе сетевых РKM-систем лежит концепция персонального графа знаний. Граф знаний представляет собой структуру, объединяющую информацию о сущностях и взаимосвязи между ними. Его узлы – это сущности, например, объекты, люди, термины, идеи и так далее. Ребра – направленные классифицированные связи.




Рис. 1 – Пример графа знаний

Подобная структура данных позволяет создавать кластеры из близких или тесно связанных сущностей, осуществлять поиск на основе ссылок, а также визуализировать базу данных.

Простые и семантически типизированные связи

Как правило, в ГЗ ребра имеют тип, который отражает характер отношения между сущностями. Это обеспечивает более продвинутую навигацию,

позволяя отсеивать нерелевантные направления на раннем этапе, что открывает возможность использовать многошаговые запросы, для обработки которых ранее не хватало вычислительных ресурсов или размера контекстного окна модели.

В механизме wikilink-ссылок, который использует Obsidian, по умолчанию нет поддержки типизации. Однако она может быть добавлена с помощью популярного расширения DataView, которое позволяет задавать тип связи при помощи следующего синтаксиса: `link_type:: [[wikilink]]`.

Специфика целевой аудитории

Основной аудиторией систем управления знаниями являются люди, чья деятельность тесно сопряжена с обработкой огромных массивов данных. Исследователи, журналисты и другие специалисты используют РKM системы для агрегации данных, создавая краткие выжимки, для их трансформации, находя пробелы в знаниях или данных, и множества других целей. Например, эти системы могут быть использованы студентами для подготовки ответов на экзаменационные вопросы на основе материалов занятий. Важно отметить, что люди зачастую используют ГЗ неявно, например, через поисковые алгоритмы или системы извлечения данных.

Постановка проблемы: Когнитивное «бутылочное горлышко»

У ГЗ есть недостаток, заключающийся в масштабировании. На начальных этапах создание ссылок и их типизация происходит естественным образом и не требует особых усилий. Однако при преодолении определенного порога по объему информации, например, при сотнях или тысячах заметок в хранилище пользователь утрачивает возможность удержать весь контекст в голове. Из-за этого процесс связывания становится трудозатратным и неточным: пользователь начинает пропускать связи, особенно неочевидные. Как следствие, граф становится разреженным и деградирует поиск, так как из-за отсутствующих связей алгоритму не удастся найти необходимую информацию. В итоге граф попросту начинает терять свою ценность.

Таким образом, алгоритм, способный автоматически анализировать

семантику заметок, находить связи между ними и типизировать их, тем самым поддерживая актуальность и плотность графа знаний, разрешит это «бутылочное горлышко» и освободит когнитивные ресурсы пользователей под другие задачи.

1.2 Технологии поиска и обработки естественного языка в системах RAG

Использование генеративных моделей в чистом виде влечет высокие риски «конфабуляций» и «галлюцинаций»: ответ модели может казаться правдоподобным, но содержать фактологические или причинно-следственные ошибки [13].

Для решения этой проблемы была разработана технология Retrieval-Augmented Generation (RAG) [4]. Она добавляет дополнительный этап поиска информации перед генерацией ответа. На основе запроса пользователя алгоритм извлекает наиболее релевантную информацию из доступных источников, таких как текстовые файлы или базы данных, после чего передает ее языковой модели в качестве контекста. Такой подход заставляет LLM выступать в роли анализатора, а не источника фактов.

Эффективность RAG-систем зависит от качества алгоритмов извлечения. В связи с этим, существует несколько подходов к поиску необходимых данных. Наиболее популярными методами являются лексический и семантический поиск.

Лексический поиск основан на точных совпадениях лексем из запроса пользователя с содержащимися в хранилищах. Данный подход отлично справляется с поиском специфических терминов, имен собственных и прочих точных формулировок, но не справляется, например, в случае замены слов на синонимы или чередующихся корней. В случае нахождения лексемы в корпусе из него извлекается фрагмент из некоторого количества предшествующих и последующих слов или предложений. Популярным алгоритмом лексического поиска является BM25 [5].

Для преодоления этих ограничений используется семантический поиск, основанный на векторном сходстве [6]. Исходный текст разбивается на фрагменты (чанки), для каждого из которых вычисляется многомерный числовой вектор

(эмбеddинг) из одного пространства. Поиск происходит путем вычисления сходства между этими векторами с помощью метрик, таких как косинусное сходство. Если полученное значение больше некоторого порога, то чанки считаются релевантными, и текст, соответствующих эмбеddингу, извлекается. Этот подход позволяет улавливать смысл текста, не основываясь на конкретных словах или формулировках.

Векторный поиск также имеет несколько недостатков [7]:

- Потеря конкретики: смысловое значение фрагментов усредняется, что ведет к потере деталей, таких как имен собственных, использованных терминов, и так далее. Чем больше чанк, тем больше деталей теряется.
- Проблема «дальних эмбеddингов»: схожие данные могут иметь сильно отличающиеся друг от друга векторы, из-за чего могут не быть найдены.

Современные RAG системы комбинируют эти подходы в так называемый гибридный поиск [7]. Он позволяет компенсировать недостатки одного подхода с помощью другого, что потенциально может увеличить полноту поиска. В нем извлеченные чанки получают унифицированную оценку и ранжируются по ней.

Несмотря на все преимущества этих подходов, обработка сложных аналитических запросов, требующих многошагового рассуждения, требует более сложных алгоритмов поиска. В случаях, когда нужная информация напрямую не связана с запросом, она не может быть найдена ни семантическим, ни лексическим поиском, из-за чего поисковый алгоритм RAG не сможет извлечь необходимые данные.

Более продвинутой стратегией поиска является Graph RAG [8]. В ней в алгоритм поиска дополняется обходом графа знаний. Для первоначального сбора вершин используется гибридный поиск. Затем начинается итеративный обход соседей на основе имеющихся ребер и их типов, что позволяет системе собирать дополнительный контекст из файлов, которые могут не содержать ключевых слов, или быть семантически далекими, но при этом логически связанными и

обладающими необходимой информацией, что позволяет значительно расширить контекст.

Языковые модели в задаче связывания. Поскольку необходимо искать тексты, обладающие не только высоким семантическим сходством или содержащие ключевые слова, нужно использовать иные от сравнения эмбедингов подходы для анализа связности текстов. Для решения этой задачи используются модели машинного обучения, такие как Cross Encoder [14] и большие языковые модели (LLM). Они позволяют реранжировать тексты на основе оценки наличия причинно-следственных, логических и иных сложных связей.

Cross Encoder являются сравнительно небольшими моделями для попарной проверки текстов. Эти модели принимают на вход два текста и совместно их обрабатывают с помощью cross-attention, что позволяет выявить более тонкие логические связи и точнее провести фильтрацию.

Большие языковые модели отлично понимают естественный язык и способны выявлять нетривиальные, многошаговые логические цепочки, которые могли быть упущены при фильтрации через Cross Encoder. Кроме того, LLM могут комбинировать фильтрацию с типизацией отношений, что позволяет решить обе задачи за один запрос. Однако такой подход является вычислительно сложным и, как следствие, дорогим, из-за чего LLM используют только для классификации и дополнительной фильтрации уже отфильтрованных пар.

1.3 Анализ существующих решений для построения графов знаний

В настоящее время на рынке представлено множество решений для управления знаниями, которые автоматизированное строят ГЗ. Они варьируются от полноценных экосистем, предназначенных для корпоративного использования до узконаправленных инструментов, решающих конкретные задачи. Проведенный анализ позволил разделить решения на три группы, выявить ограничения и хорошие практики существующих решений, а также сформировать базовый набор технологий, применяемый при построении ГЗ в

контексте систем управления знаниями.

Готовые решения для корпоративного использования. В данную категорию включены полноценные экосистемы, позволяющие автоматически трансформировать пользовательские текстовые данные в графы знаний при помощи LLM. Представителями этой категории являются такие решения как Neo4j Graph Builder [9] и Memgraph Unstructured2Graph [10]. Сами Neo4j и Memgraph являются графовыми базами данных, предоставляющими широкий функционал «из коробки», в том числе возможность извлечения сущностей и связей из пользовательских текстовых данных различных популярных форматов для построения ГЗ на их основе.

Поскольку данная работа фокусируется на построении ГЗ, в этих решениях будет изучен исключительно ответственный за это модуль. Оба решения имеют открытый исходный код этих модулей. За основу взят пайплайн Neo4j, однако логика Memgraph крайне схожа. Изученный конвейер состоит из нескольких этапов:

1. Парсинг и чанкинг. Исходные данные разбиваются на фрагменты размером 4000 символов и перекрытием 200 символов [<https://github.com/neo4j-labs/llm-graph-builder>].
2. Извлечение сущностей. Каждый чанк передается в LLM с инструкциями для извлечения троек (Entity A – [relation type] – Entity B).
3. Разрешение кореференций. Извлеченные имена сущностей дедуплицируются с помощью большой языковой модели для избежания конфликтов (например, сущности «ИИ» и «Искусственный интеллект» объединяются в одну с именем «Искусственный интеллект»).
4. Запись данных. Обработанные данные записываются в базу данных. Они формируют два графа: лексический, сохраняющий последовательность фрагментов в файле, и семантический, содержащий связи между сущностями.

5. Создание сообществ. Используются графовые алгоритмы (Louvain, PageRank) для поиска сообществ, что позволяет создавать кластерные узлы (хабы), увеличивающие эффективность навигации RAG.

Neo4j и Memgraph используют LangChain [15] для работы с LLM, что позволяет использовать множество провайдеров, а также запущенные локально модели.

Данные системы обладают рядом преимуществ:

1. Поддержка множества форматов текстовых данных, таких как PDF, HTML и DOCX.
2. Построение двухуровневых графов: лексический, отражающий последовательность фрагментов текстов, и граф сущностей, соединенных типизированными связями. Это упрощает сбор всего содержимого одной заметки, например, в случае необходимости пересказа ее содержимого
3. Формирование сообществ с описаниями, что экономит контекст при ответе на общие вопросы, затрагивающие множество заметок на общую тему.

Однако они также имеют ряд критических недостатков, ставящих под сомнение использование подобных решений для персональных баз данных.

1. Отсутствие поддержки частичного обновления. Даже при минимальных модификациях файлов необходимо полностью перезапускать дорогостоящий пайплайн для построения ГЗ.
2. Разрыв между данными и графом. Поскольку в этих сервисах отсутствуют механизмы синхронизации содержимого заметок, пользователю необходимо вручную загружать обновленные файлы на сервер базы данных, что увеличивает вероятность ошибок и делает процесс более трудоемким.
3. Инфраструктурные издержки. Для обработки данных и взаимодействия с ГЗ необходима работающая база данных, что ведет к потреблению

дополнительных вычислительных ресурсов, и, как следствие, дополнительным затратам, если сервис работает на выделенном сервере.

4. Чрезмерное доверие к LLM. В пайплайнах этих решений отсутствует фильтрация кандидатов. В них вся работа по извлечению сущностей и анализу связей полностью лежит на больших языковых моделях, которым свойственны «галлюцинации». Это влечет создание бессмысленных и выдуманных связей, которые делают извлечение информации неэффективным.

Академические автоматизированные пайплайны. В качестве альтернативы решениям, опирающимся на использование тяжеловесных LLM было найдено решение [16], эффективно использующее сравнительно небольшие модели и другие методики для построения ГЗ.

Его пайплайн состоит из следующих этапов:

1. Чанкинг. Файлы разбиваются на фрагменты, каждый из которых будет обрабатываться независимо, то есть для каждого чанка будет создан независимый ГЗ.
2. Извлечение сущностей. Вместо больших языковых моделей данное решение использует компактную модель SqueezeBERT [17]. Процесс извлечения аналогичный: в модель передается фрагмент текста и инструкции.
3. Привязка к онтологиям. Для стандартизации имен сущностей и снижения галлюцинаций все извлеченные сущности сверяются с базами данных, такими как DBpedia или Wikidata.
4. Вычисление семантического сходства. Для создания связей между сущностями используется сравнение косинусного сходства их плотных эмбедингов, созданных моделью Sentence-BERT [18], с пороговым значением.

5. Слияние графов. Все ГЗ, построенные для фрагментов текстов объединяются в единую сеть на основе общих узлов и связей.

Ключевые достоинства этого подхода включают:

1. Вычислительную эффективность. Использование небольших моделей машинного обучения сильно экономит вычислительные ресурсы и позволяет использовать решение полностью локально.
2. Использование онтологий. Это решение упрощает этап разрешения кореференций, уменьшая вероятность галлюцинаций и убирая необходимость использования LLM для дедупликации.

У данного решения есть несколько недостатков, делающими этот подход неподходящим для решения главной проблемы этой работы.

1. Обязательное участие человека. Поскольку авторам важно качество полученного ГЗ, сгенерированный граф тщательно корректируется человеком, что делает процесс лишь частично автоматизированным.
2. Малое разнообразие сущностей. Использование жестких списков допустимых сущностей может повлечь ошибочную фильтрацию непопулярных терминов или аббревиатур.

Облачные приложения для заметок. Индустрия также имеет примеры приложений для ведения заметок, которым удалось интегрировать ГЗ для увеличения эффективности их использования.

Облачные сервисы, такие как Mem.ai [11], являются программным обеспечением как услугой (SaaS), полностью разгружая пользователя от организации и связывания заметок. Mem.ai, по аналогии с MemGraph и Neo4j, строит двухуровневый граф (лексический слой, сохраняющий последовательность фрагментов в файле, и семантический, содержащий связи между сущностями). Это обеспечивает эффективную навигацию алгоритмам

RAG. В данном сервисе ГЗ используются как для подсказок во время написания заметок, так и для извлечения и синтеза информации посредством интегрированного чат-бота.

Несмотря на все удобства, у Mem.ai существуют недочеты, касающиеся приватности и обработки данных:

1. **Закрытый исходный код.** Пользователи не имеют доступа к логике построения ГЗ и обработки их заметок.
2. **Привязка к поставщику.** Данные хранятся на серверах компании, что ставит под сомнение их безопасность, и делает их экспорт в случае закрытия сервиса затруднительным: сервис предоставляет возможность экспорта сырого текста заметок, но не ГЗ.

Плагины Obsidian. Приложение имеет поддержку пользовательских расширений, которые добавляют новый функционал в программу. По результатам исследования выяснилось, что расширений, позволяющих автоматизировать процесс построения ГЗ не существует. Несмотря на это, есть плагины-ассистенты, упрощающие некоторые его этапы.

1. **Smart Connections** [19]. Плагин, использующий векторный поиск для формирования списка схожих заметок. Инструмент способен находить только семантически близкие заметки. Кроме того, плагин не проводит никакой дополнительной фильтрации результатов, а также не типизирует результаты, чем перекладывает большую часть работы на пользователя.
2. **Graph Analysis** [20]. Инструмент, подсказывающий связи на основе существующих. Данное решение опирается только на уже построенный граф для вычисления статистик, на основе которых предлагает пользователю новые связи или хабы. Данный плагин может хорошо работать как дополнение к автоматизированному пайплайну построения ГЗ, но не как его замена.

Выводы. Решения, представленные на рынке в данный момент, заставляют пользователей идти на компромиссы. С одной стороны есть либо полноценные дорогостоящие и требовательные к ресурсам базы данных, либо закрытые облачные решения для ведения заметок, которые все же решают задачу автоматизированного построения ГЗ. С другой стороны существуют открытые легковесные инструменты, позволяющие упростить некоторые этапы построения, но требующие вмешательства человека.

Решение с открытым исходным кодом, способное вычислительно эффективно находить, фильтровать, типизировать и сохранять связи, а также поддерживающее работу полностью локально, имело бы огромное преимущество на фоне изученных решений. Плюсом будет возможность модификации построенного графа пользователем, как и поддержка инкрементальных обновлений.

1.4 Методология оценки качества

Для объективной оценки разрабатываемого пайплайна и его сравнения с аналогами необходимо создать методологию тестирования. Процесс тестирования требует как подготовки валидационного датасета, так и выбора подходящих метрик.

Имитация графа знаний в среде Obsidian и требования к данным

Благодаря гибкости Obsidian и нативной поддержки ссылок, создание ГЗ в нем будет выглядеть естественно. В качестве сущностей будут выступать Markdown-файлы, а в роли семантических связей гиперссылки. В данной работе будут также рассматриваться типизированные ссылки в Obsidian, которые добавляет расширение Dataview.

Также необходимо установить ряд ограничений для сохранения каноничности графа, а также упрощению работы с ним.

1. Корпус текстов должен обладать высокой семантической связностью, то есть между файлами должны быть ярко выраженные семантические отношения

(иерархические, причинно-следственные, функциональные и другие).

2. Содержание каждого файла должно быть целостным и описательным. Поскольку языковые модели нуждаются в контексте, они будут неустойчиво работать на обрывках текста или фрагментах кода.
3. Объем подкорпуса не должен превышать 10-15 заметок. Данное ограничение призвано облегчить ручную разметку и касается исключительно валидационного датасета, создаваемого в рамках данной работы. В случае превышения этого порога, разметка станет крайне затруднительной, а также увеличатся риски потери связей.
4. Заметка должна представлять одну сущность.
5. Замкнутость множества сущностей и отсутствие автореференций. Пространство допустимых сущностей задается файлами в хранилище. При этом создание рефлексивных связей (когда заметка ссылается сама на себя) не допускается.

Раскроем четвертое структурное ограничение подробнее. Оно означает, что в содержании файла должна находиться информация только об одной конкретной сущности, такой как личность, термин, событие, и так далее. Содержание файла может включать в себя описание этой сущности, ее определение, историю, факты, а также описание связей с другими сущностями. Во-первых, такой подход делает хранилище максимально похожим на граф знаний. Во-вторых, это упрощает работу алгоритма, поскольку отпадает необходимость извлекать сущности. так как файлы в нем формируют список допустимых сущностей. В-третьих, этот подход отлично сочетается с философией связывания файлов в Obsidian, в которой связываются файлы целиком, а не фрагменты их содержимого.

Стратегия валидации

Оценка такой комплексной системы от начала до конца является некорректной, так как она может скрывать ошибки промежуточных этапов.

Например, если на этапе извлечения были получены нерелевантные чанки, то этап классификации заведомо провалится, так как он не получит нужных данных. В связи с этим валидация конвейера будет разделена на три этапа: оценку извлечения контекста, оценку типизации отношений, а также оценку сгенерированного графа для использования в RAG-системах. Такой подход даст возможность изолированного измерения качества работы каждого модуля системы и его тонкой настройки, что положительно скажется на итоговом качестве пайплайна.

Оценка извлечения контекста

Оценку retrieval можно сформулировать как задачу воспроизведение контекстов, в которых упоминается сущность: для каждой пары (s, e) , где s — файл-источник (`source_file`), а e — целевая сущность (`entity`), система должна вернуть фрагмент из текста s , в достаточной мере совпадающий с эталонным контекстом из «золотого стандарта». Извлеченный фрагмент должен полностью содержать эталонное предложение.

Важно заметить, что при больших чанках вероятность случайно захватить нужное предложение выше. Однако о данном замечании не стоит беспокоиться, так как извлекаемые фрагменты не могут быть слишком большими, так как это негативно повлияет на качество эмбедингов.

Извлеченные фрагменты текста подразделяются на две категории:

- Явное упоминание сущности. В данную группу входят все предложения, которых используется имя сущности. Например, предложение «Билл Гейтс соосновал Microsoft» явно содержит название компании.
- Косвенное упоминание сущности. В этот класс входят предложения, в которых имя сущности заменено на местоимение. Например, в тексте «Microsoft была основана 4 апреля 1975. Билл Гейтс был одним из тех, кто ее соосновал» местоимение ее подразумевает Microsoft.

Для оценки необходимо создать специальный датасет, состоящий из

предложений с упоминаниями сущностей, списка упомянутый сущностей, а также типа упоминания (явное или косвенное).

Оценка LLM-классификации

Оценка типизации связей сводится к задаче классификации направленного отношения для упорядоченной пары сущностей (e_1, e_2) . При условии, что retrieval предоставил набор релевантных фрагментов, большая языковая модель должна определить наличие связи от e_1 к e_2 , и присвоить ей один из представленных классов. В случае присвоения недопустимого класса или ответа модели о несвязанности сущностей (классификации как отдельный класс `no_relation`), ссылка отбрасывается.

Для оценки качества классификации используются стандартные метрики [21]:

- Точность (Precision) – доля истинных связей среди всех предсказанных алгоритмом. Метрика важна для оценивания алгоритма на устойчивость к шуму. В случае создания множества ложноположительных связей граф засорится и потеряет свою ценность.
- Полнота (Recall) – доля истинных связей из датасета, которые алгоритм смог успешно идентифицировать и типизировать.
- Взвешенная F-мера (Weighted F₁-score) – гармоническое среднее между точностью и полнотой. Эта метрика устойчива к дисбалансу в типах связей: зачастую в данных универсальные классы (такие как упоминания или дополнения) встречаются значительно чаще, чем, например, опровержение или противопоставление. Она будет использоваться в качестве основной оценки.

Полная оценка GraphRAG

Для комплексной оценки ответов, сгенерированных LLM на основе контекста, предоставленного RAG, используются специализированные фреймворки, такие как RAGAS [22]. Их фундаментальной идеей является

использование LLM как судей для оценки ответов других языковых моделей, что позволяет оценивать семантику ответов, а не использованные в них слова.

В данной работе будет использован фреймворк RAGAS. Из метрик, предоставляемым им, будут подсчитываться:

- Точность извлеченного контекста (Context Precision, CP). Данная метрика оценивает способность RAG систем извлекать релевантную информацию и ранжировать ее по мере соответствия. В RAGAS каждый извлеченный фрагмент текста оценивается на наличие и долю в нем нужной для ответа информации. Высокое значений CP говорит о предоставлении языковой модели релевантных данных с минимальной долей шума в них.
- Полнота извлеченного контекста (Context Recall, CR). Эта метрика оценивает RAG на умение собирать всю необходимую для ответа информацию. Для расчета этой метрики эталонный ответ разбивается на независимые атомарные утверждения, каждое из которых оценивается на возможность вывода его на основе извлеченных данных. Чем больше утверждений в эталонном ответе могут быть выведены, тем выше значение метрики.
- Достоверность ответа (Answer Faithfulness, F) направлена на измерение достоверности ответа, то есть степени, в которой сгенерированный ответ опирается исключительно на предоставленный контекст, а не на знания самой модели. Процесс оценки заключается в выделении всех тезисов в ответе и проверку возможности их подтверждения на основе предоставленных фрагментов текстов. Если модель использовала в ответе внешнюю информацию, то мера достоверности снижается.
- Корректность ответа (Answer Correctness, AC) измеряет семантическое и фактологическое соответствие сгенерированного ответа эталонному. В фреймворке RAGAS она вычисляется как взвешенная сумма фактологического перекрытия (доля фактов, присутствующих как в ответе

системы, так и в эталоне) и семантического сходства эмбедингов двух ответов.

Использование такого набора метрик позволяет получить полную картину работы пайплайна: от способности алгоритма GraphRAG предоставить релевантную информацию, до способности модели использовать предоставленную информацию для генерации ответа.

Моделирование сложных сценариев для тестирования

Чтобы проверить устойчивость алгоритма и его применимость в реальных условиях использования, необходимо выявить наиболее сложные или важные ситуации, с которыми встречаются алгоритмы построения ГЗ и GraphRAG.

- **Обнаружение сообществ.** Сообщества – подграфы, вершины внутри которых плотно связаны между собой, но слабо с внешними. Они формируются из сущностей из одной тематики. Например, заметки с рецептами создают один кластер, а конспекты лекций по машинному обучению – другой. Современные алгоритмы ГЗ обычно автоматически их обнаруживают и создают для них отдельную вершину, в которой содержится краткая сводка. Эти вершины полезны при ответе на широкие вопросы, такие как «Какие темы из области математического анализа я изучал в этом месяце?», а также для навигации алгоритмов поиска релевантных заметок. Они убирают нужду каждый запрос проходить по всем вершинам и обобщать их содержимое. Поскольку алгоритм, представленный в этой работе, не будет искать и создавать сообщества, уместно оценить возможность находить уже созданные.
- **Проверка на устойчивость к шуму.** В данном случае можно использовать омонимию, то есть слова или термины, совпадающие по написанию, но различные по смыслу. Такая структура заставит алгоритм использовать содержимое заметок для поиска и фильтрации. Также возможно создание графа из тесно связанных сущностей, что позволит протестировать

способность алгоритма улавливать тонкие различия между типами связей в однородном тексте.

- Многошаговый поиск. Линейные цепочки из заметок, где каждая вытекает из предыдущей, проверяет эффективность поиска длинных логических путей.

РАЗРАБОТКА АЛГОРИТМОВ

2.1 Архитектура алгоритма построения графа знаний

Разработанная система является конвейером для автоматического нахождения, типизации и инкрементального сохранения семантических связей между заметками (Markdown-файлами) в хранилище Obsidian. Процесс построения состоит из нескольких шагов: от сканирования хранилища до записи найденных отношений в файлы. Алгоритм поддерживает сохранение состояния файлов в директории и контрольные точки (checkpoints), которые позволяют алгоритму продолжить работу с момента прерывания и нацелены на сохранение вычислительных ресурсов. Алгоритм реализован на языке Python (исходный код доступен в папке `src/kg_builder`).

Общая схема конвейера представлена на рисунке 2.



Рис. 2 – Общая схема конвейера построения графа знаний

Этап 1. Сканирование хранилища и обнаружение изменений (VaultManager)

На этом этапе модуль `VaultManager` рекурсивно обходит директорию хранилища, формируя список всех `markdown`-файлов. Для каждого файла вычисляется `SHA-256` хеш-сумма его содержимого для идентификации изменений. Полученный хэш сравнивается с сохраненным в метаданных (`metadata.json`), с предыдущего запуска. В результате файлы разбиваются на три категории: новые (отсутствующие в метаданных), измененные (не совпадает хеш) и удаленные (есть в метаданных, но отсутствует на диске). Если метаданных нет, то все файлы считаются новыми.

Данный подход позволяет экономить вычислительные ресурсы, поскольку позволяет обрабатывать только измененные файлы, а не все хранилище целиком.

Этап 2. Разбивка на чанки и индексация (VectorStore / LanceDB).

Каждый новый или измененный файл проходит процесс индексации. Эта процедура состоит из двух частей: обработки содержимого заметок и подготовки индексов.

Изначально текст каждого Markdown-файла состоит из двух частей: основного содержимого и блока ссылок, разделенными отделенным заголовком `link_header`. Индексируется только основной текст заметки.

Текстовый индекс строится на основе лемматизированного содержимого файлов. Лемматизация проводится при помощи модели `ru_core_news_sm` или `en_core_web_sm` из `spaCy`. Из текстов извлекаются леммы всех алфавитных и числовых токенов в нижнем регистре. Преобразованные тексты передаются в LanceDB [23], где на них строится FTS-индекс, использующий алгоритм BM25. Данный подход позволяет увеличить точность поиска, нивелируя проблему, связанную с изменением форм слов, в которых, например, могут быть изменены окончания или беглые гласные в корне, что особенно распространено в русском языке. Стоит отметить, что вместе с преобразованным текстом сохраняется и оригинальный.

Построение векторного индекса начинается с разбиения содержимого файла на перекрывающиеся чанки. Используется рекурсивное посимвольное разбиение (`RecursiveCharacterTextSplitter` из `LangChain`). Данная стратегия разбивает текст иерархически по заданным разделителям, расположенным в порядке их приоритета, (символ новой строки, точка и т.д.), при этом не превышая заданный размер чанка (по умолчанию 3,000 символов). Она стратегия сохраняет целостность предложений и структуру Markdown-файлов, что крайне важно для вычисления эмбедингов и формирования контекста для LLM.

Далее для каждого чанка следует вычисление плотного векторного эмбединга при помощи модели из `Sentence-Transformers`, например популярной мультязычной модели `BAAI/bge-m3`.

Полученные индексы объединяются друг с другом, а также с метаданным в виде пути к файлу и хеша, после чего сохраняются в базу данных. Хранение обоих форматов данных в одной таблице позволяет использовать гибридный поиск. LanceDB позволяет регулировать баланс между векторным и полнотекстовым поиском при помощи параметра `vector_weight` $\in [0,1]$: при `vector_weight = 1.0` используется только ANN-поиск, при `vector_weight = 0.0` — только BM25, промежуточные значения используют оба поиска, сортируя результаты по унифицированной оценке релевантности.

Этап 3. Гибридный поиск пар-кандидатов (Retrieval).

На данном этапе для каждого чанка выполняется поиск семантически близких чанков из других файлов. Доступно три стратегии поиска:

- `broad`, основанная на векторном поиске. Для каждого чанка текущего файла производится поиск k ближайших соседей из других файлов. Второй подход позволяет искать схожие чанки на основе семантики всего файла, что значительно сократит уровень шума и ускорит процесс, но может не найти часть релевантных фрагментов.
- `strict`. Она основана на поиске прямых упоминаний сущностей в текстах заметок. Поиск производится по лемматизированному тексту, что решает проблему словоизменения, несовпадения регистров и использования специальных символов, таких как дефис. (например, имя «Нейронная сеть» будет найдено в тексте «нейронной сети»)
- `combined` объединяет обе стратегии с дедупликацией. Результаты `broad` и `strict` проходят характерный им пайплайн извлечения и обработки, после чего фрагменты объединяются и дедуплицируются с помощью коэффициента Жаккара. Дедупликация заключается в сравнении содержимого чанков, извлеченных каждой стратегией, друг с другом. Если фрагмент, извлеченный `strict`, будет иметь коэффициент с фрагментами, извлеченными `broad`,

больше 0.7, то чанк от broad будет отброшен. Результаты *strict* приоритизируются, так как к ним больше кредит доверия.

Как было описано в главе 1.2, каждая стратегия имеет свои компромиссы. Строгое извлечение имеет высокую точность, но низкую полноту - она может найти только явные упоминания. Векторный поиск может находить косвенные упоминания, но он очень шумный. Результат его работы требует дополнительной фильтрации, что все равно не гарантирует отсутствие ложноположительных результатов. Комбинированный подход задуман сгладить недостатки этих стратегий путем извлечения как прямых упоминаний, так и косвенных, хоть и допуская шум.

Результатом поиска является *INITIAL_RETRIEVAL_K* фрагментов текста.

Этап 4. Переранжирование кандидатов (Cross-Encoder).

Данный этап имеет место только для векторного поиска, поскольку он зачастую возвращает большое число ложноположительных кандидатов.

Для снижения шума применяется дополнительная фильтрация кандидатов с помощью Cross Encoder. Каждая пара (чанк источника, чанк цели) подается на вход Cross Encoder (модель типа BAAI/bge-m3 / MiniLM) с инструкцией-вопросом. Кросс-энкодер вычисляет более точную оценку семантической связности. Пары сортируются по убыванию оценки. В финальный список попадают *RERANKER_TOP_K* пар, у каждой из которых оценка не ниже порогового значения.

Все прошедшие фильтрацию чанки группируются по файлу-цели. На их основе создаются структуры *CandidatePair*, содержащие исходный и целевые чанки, а также пути к соответствующим файлам и оценку близости из LanceDB и Cross Encoder.

Результатом этапа является список структур *CandidatePair*, к которым добавлены результаты лексического поиска, если он был использован. Важно уточнить, что результаты стратегии *strict* являются более приоритетными, а

результаты стратегии `broad` добавляются в итоговый список по остаточному принципу.

Этап 5. Классификация типа связи (LLM).

Прошедшие фильтрацию пары-кандидаты передаются в языковую модель для определения точного типа семантической связи. Пары группируются по комбинации (файл-источник – файл-цель). Для каждой такой группы отбираются не более *LLM_TOP_K_CTX* наиболее релевантных чанков для формирования контекста на основе оценки Cross Encoder.

Логика запросов к LLM поддерживает параллелизм и батчинг. Количество одновременных запросов к модели ограничено заданным числом и контролируется семафором. Кроме того, в рамках одного запроса может проводиться классификация сразу нескольких ссылок. Это значительно снижает накладные расходы и время обработки.

Важно отметить обработку ошибок: у каждого батча есть три попытки, при израсходовании которых батч откладывается и логируется ошибка. Он будет повторно обработан при следующем запуске.

В рамках запроса модель получает системный промпт со списком допустимых типов связей и инструкциями, а также пользовательский промпт с парами файлов и их контекстом.

Ответ модели возвращается в формате JSON. Его парсинг производится посредством `JsonOutputParser` из `LangChain`, позволяющий восстанавливать синтаксически некорректный JSON. При возврате моделью раздела с размышлениями, он логируется и вырезается для упрощения парсинга.

Для работы с LLM используется `LangChain`. Благодаря его использованию поддерживаются как локальные модели (например, запущенные через `llama.cpp` [24]), так и облачные провайдеры (OpenAI, Google, и другие).

После каждого батча предсказания модели сохраняются в файл, формируя контрольную точку, что позволяет возобновить классификацию в случае ошибки

или краша программы. Данная оптимизация призвана экономить вычислительные ресурсы, убирая потребность заново делать выполненную работу.

Этап 6. Сохранение связей (ExportService).

На заключительном этапе классифицированные связи сохраняются в одном из трех режимов:

- `inplace`. Связи добавляются непосредственно в исходные Markdown-файлы под специальным заголовком `LINK_HEADER`. При наличии связей с предыдущих запусков новые связи неdestructивно добавятся к уже имеющимся, не создавая дубликатов.
- `json`. Результаты экспортируются в JSON-файл без изменения исходных заметок. Данный режим создан для удобного переиспользования результатов, например для вычисления метрик.
- `export`. Создается полная копия хранилища с вписанными связями, исходные файлы остаются нетронутыми. Этот формат сохранения полезен для экспериментов, таких как оценка GraphRAG, требующих полноценное хранилище для работы.

Формат ссылки конфигурируется (по умолчанию используется синтаксис `Dataview: - relation:: [[target]]`).

Управление состоянием и отказоустойчивость (MetadataManager).

При первом запуске конвейера стандартные параметры из `config.py` сохраняются в `config.json` внутри директории `.kg_builder/`. Последующие запуски считывают этот файл и выставляют настройки, заданные в нем, что обеспечивает воспроизводимость и повышает удобство использования на разных хранилищах с индивидуальными параметрами.

Опция `--ignore-local-config` заставляет пайплайн проигнорировать `config.json` и использовать значения из `config.py`.

Алгоритм сохраняет свое состояние с помощью создания снимка, который включает текущий этап (сканирование хранилища, сбор кандидатов, классификация, и т.д.), его прогресс и прочие метаданные, необходимые для возобновления работы.

Наибольшей детализацией обладают этапы ранжирования кандидатов и LLM-классификации отношений. У них есть логика контрольных точек, при которых сохраняется список уже обработанных файлов или пар-кандидатов. При возобновлении работы пайплайна на одном из этих шагов в алгоритм будут переданы только необработанные данные.

При последующих запусках `KnowledgeGraphBuilder` проверяет последнее сохраненное состояние. Если предыдущий запуск был прерван, то он продолжит обработку с того же шага, минуя уже выполненные.

Это сохраняет значительное количество вычислительных ресурсов и времени, особенно на дорогостоящем LLM-этапе.

Все метаданные сохраняются в отдельной директории `.kg_builder/.out/`:

- `candidates.json` — начальные кандидаты до переранжирования;
- `reranked_candidates.json` — кандидаты после переранжирования, обогащенные результатами LLM (поля `llm_type`, `llm_reasoning` дописываются после классификации)
- `predictions_partial.json` — предсказания LLM, обновляемые инкрементально
- `run_state.json` — текущее состояние алгоритма

Специальный флаг `--fresh-start` позволяет перезаписать метаданные, в том числе конфиг и список обработанных файлов. Он может быть полезен при разработке, случаях, когда модифицируется структура метаданных, или они были повреждены.

2.2 Алгоритм GraphRAG

В качестве референсного решения был выбран ObsidianRAG [25]. Его алгоритм состоит из нескольких шагов:

1. Индексация: содержимое markdown-файлов разбивается на чанки разметом 1500 символом с перекрытием в 300 символов. Полученные фрагменты вместе с извлеченными из текста ссылками записываются в ChromaDB - векторную базу данных - которая создает для них плотные векторные эмбединги.
2. Первоначальный поиск: запрос пользователя обрабатывается с помощью EnsembleRetriever, использующим BM25 и ANN с весами 0.4 и 0.6 соответственно. Извлекается N наиболее релевантных заметок.
3. Переранжирование: полученные файлы передаются в Cross Encoder, например, BAAI/bge-reranker-v2-m3. В результате фильтрации остается 6 наиболее близких фрагментов.
4. Расширение контекста: результат дополняется пятью файлами, связанными ссылками с оставшимися.
5. Генерация ответа: собранное содержимое заметок передается в локальную LLM (Ollama).

У данного пайплайна есть ряд недостатков:

1. Одноэтапное расширение контекста соседями. При таком подходе теряются сложные связи, требующие многошаговых рассуждений. А также возрастает вероятность остаться в семантической ловушке: ситуации, когда новая информация не может быть извлечена из-за сильной разницы в эмбедингах и ключевых словах. Суть ссылок заключается в решении этой проблемы, но автор ими пренебрегает.

2. Сбор контекста без учета его релевантности. В проекте уже используется Cross Encoder для первоначального поиска, его можно легко переиспользовать для фильтрации фрагментов, не относящихся к запросу.

На основе этого решения был разработан улучшенный четырехэтапный пайплайн, поддерживающий типизированные ссылки и многошаговое расширение контекста. Он нацелен на решение фундаментальных проблем эталонного решения. Алгоритм реализован на языке Python (исходный код доступен в папке `src/graphrag`).




Рис. 3 – Общая схема конвейера GraphRAG

Этап 1. Первоначальный поиск. На этом этапе выполняется гибридный поиск по LanceDB. Он включает в себя ANN-поиск по плотным эмбедингам и BM25-поиск по лемматизированному тексту. На его основе собирается *TOP_K_SEED* (по умолчанию = 5) наиболее близких заметок-кандидатов. Они добавляются в множество посещенных файлов.

В отличие от референсного решения, на данном этапе не выполняется переранжирование заметок с помощью Cross Encoder. Оно было перенесено на шаг 3. Это решение было принято исходя из точности алгоритма извлечения,

а также для смягчения критериев для отбора заметок, что потенциально может увеличить полноту собранного контекста.

Этап 2. Обход соседей.

Расширение контекста может быть проведено двумя способами:

- Базовый обход в ширину. Для каждой заметки формируется список исходящих ссылок. Типы ссылок при этом игнорируются, как и релевантность их содержимого. Все непосещенные файлы, соединенные с текущим, добавляются в очередь для обхода.
- Типизированный обход в ширину. Для каждой заметки, связанной с текущей, формируется запрос в Cross Encoder модель формата:

```
relation: target. summary
```

где `relation` – тип связи, `target` – имя целевой заметки, `summary` – ее краткое содержание (первый абзац). Cross Encoder вычисляет оценку близости соседней заметки с текущей. Все кандидаты с оценкой ниже пороговой не добавляются в очередь обхода. Это позволяет фильтровать заметки на этапе сбора контекста, что может снизить количество шума, но также уменьшить полноту контекста из-за раннего отброса.

Результатом этапа является множество потенциально релевантных заметок.

Наглядное сравнение стратегий обхода представлено в таблице 1.

Критерий	Base	Typed
Тип связи	Игнорируется	Включается в оценку
Оценка кандидатов	Отсутствует	Cross Encoder
Текст для оценки	—	relation: target. summary
Фильтрация	Нет (все соседи)	Пороговая по оценке
Ограничение числа новых узлов	Нет	Нет

Таблица 1 – Сравнение стратегий обхода графа

Этап 3. Отбор содержимого. Содержимое каждой заметки, отобранной на предыдущем этапе, разбивается на фрагменты с помощью того же сплиттера, что используется при индексации хранилища (глава 2.1).

Каждый полученный чанк получает оценку Cross Encoder схожести с запросом пользователя. Сохраняется *TOP_K_CONTEXT* (по умолчанию 10) наиболее релевантных фрагментов, которые сформируют итоговый контекст и будут отправлены в LLM.

В отличие от референсного решения, в котором фильтрация происходит на этапе сбора контекста, здесь происходит отбор всего собранного содержимого заметок после обхода графа. Это позволяет увеличить полноту выборки, но допускает наличие в ней большего количества нерелевантных фрагментов.

Этап 4. Генерация ответа. Запрос в LLM формируется на основе промпта, который дает модели необходимые инструкции (например, отвечать на языке пользователя, несмотря на язык предоставленного контекста, и опираться только на предоставленные данные), сообщения пользователя и отобранных фрагментов текстов markdown-файлов, разграниченные специальным разделителем.

Предсказание модели преобразуется в формат JSON с помощью `JsonOutputParser` из `LangChain`. В ответе ожидается два поля: `reasoning` – рассуждения модели, и `answer` – финальный ответ, возвращаемый пользователю. В случае неудачного парсинга возвращается сырой ответ модели.

СБОР И ПОДГОТОВКА ДАННЫХ

Для оценки качества работы пайплайна и возможности сравнения его с аналогами необходимо создать репрезентативный датасет, который бы удовлетворял требованиям, описанным в главе 1.4.

3.1 Поиск данных

В качестве первичной гипотезы рассматривалось использование существующих открытых пользовательских хранилищ в формате Obsidian с их последующей модификацией и фильтрацией. В ходе поиска было отобрано несколько качественных репозиторий:

- личные заметки общего назначения [26];
- структурированная документация коллектива *Hundred Rabbits* [27];
- корпус кулинарных рецептов *based.cooking* [28];
- заметки по программной инженерии [29].

После их детального анализа выявился один общий критический недостаток: нарушалось правило “заметка = сущность”. Наиболее распространенной причиной его нарушения были склейки текстов на разные тематики в одном файле.

Помимо структурного несоответствия был выявлен ряд дополнительных недостатков:

- Семантическая разреженность данных. Некоторые хранилища состояли в основном из дневниковых записей, заметок или рецептов, между которыми практически не было связей, либо они были неоднозначными.
- Несоответствие объема. Почти все найденные хранилища были либо слишком малы, либо слишком велики. К репозиториям с недостающим объемом пришлось бы искусственно добавлять данные, а из слишком

больших удалять, что потенциально может создать массу висячих ссылок и спровоцировать потерю ценных связей и контекста.

- В некоторых репозиториях отсутствует явная указанная лицензия либо присутствуют фрагменты текстов или кода, потенциально нарушающие авторские права. Это делает обработку этих данных рискованной.

Выбор Википедии как основного источника данных. В качестве следующего источника данных было решено рассмотреть Википедию. У нее есть ряд важных преимуществ:

- Естественная атомарность статей. Зачастую статьи соответствуют одной сущности, что согласуется с правилом “одна заметка = одна сущность”.
- Наличие ссылок. В статьях изначально есть гиперссылки на другие статьи. Эти ссылки образуют граф, к которому можно получить доступ и использовать его как для сбора данных, так и для первоначальной разметки.
- Качество содержимого. Подавляющая часть популярных статей написана в энциклопедическом стиле, обладает высокой плотностью информации, ее последовательным и связным изложением.

Все вышеперечисленное делает Википедию подходящим источником данных для валидационного датасета.

3.2 Создание валидационного датасета

Построение датасета и восстановление связей. Формирование базового датасета проводилось при помощи Wikipedia API, обращение к которому производилось посредством библиотеки `wikipediaapi`. Данный инструмент позволяет сохранять тексты статей, а также предоставляет доступ к графу из ссылок. Важно отметить, что граф поддерживает типизацию ребер, что также поможет формированию датасета. Однако лишь малая его часть размечена, и в основном это ссылки, соединяющие популярные статьи.

Важно отдельно отметить, что статьи имеют специальный раздел, содержащий краткую сводку (summary). Он будет использован в качестве контекста пайплайном GraphRAG для фильтрации заметок на этапе сбора контекста.

Формирование структуры элементов датасета. Поскольку ресурсы ограничены, необходимо определить несколько наиболее показательных сценариев для оценки алгоритма. На основе анализа особенностей работы GraphRAG, описанных в главе 1.2, был составлен список наиболее показательных структур элементов валидационного датасета и их содержимого:

- **Hub-n-spoke (Hub).** Структура в форме граф в виде звезды, состоящая из статьи-хаба и ее соседей. Главная задача алгоритма в этом случае - идентификация хаба. Алгоритмы GraphRAG зачастую пытаются обнаружить именно такие узлы, так как они дают непосредственный доступ к большому количеству информации. Тематика датасета – производство полупроводников и микроэлектроника. Итоговый набор статей включает как общие концепции (закон Мура, фотолитография, кремний), так и конкретные технологии или компании (ASML, TSMC, транзисторы, архитектура ARM, Apple M1).
- **Versus.** Структура, состоящая из двух разных тематик, которые местами могут показаться схожими. Например, Apple как компания и apple как яблоко. Такой подход заставит алгоритм работать с содержимым заметок, а не только с названиями сущностей. В собранном наборе данных эта структура реализована на примере явления омонимии: корпорация Apple (включая связанные узлы, например, Стив Джобс, iPhone, macOS) противопоставляется яблоку как фрукту (яблочный пирог, сорт Грэнни Смит) и связанным с ним историческим фактам (Исаак Ньютон).
- **Realistic.** Данный элемент будет содержать две схожие тематики. Его задача - проверка созданных алгоритмом связей на шум. Для датасета было решено связать концепции искусственного интеллекта (перцептроны, машинное обучение, обратное распространение ошибки и т.д.) с их историей.

- **Sequence.** Образец, состоящий из последовательных или вытекающих друг из друга событий или терминов. В качестве предметной области для этого набора была выбрана хронология развития представлений о строении атома (от открытия катодных лучей и электрона до пудинговой модели, экспериментов Резерфорда и модели Бора). Этот подкорпус будет нацелен на проверку способности алгоритма находить сложные, многошаговые связи.
- **Personal.** Элемент, созданный в ручную по аналогии с ежедневными заметками и содержащий различные события, планы, наброски идей. В нем смоделированы типичные личные записи: привязки к датам, повседневные задачи (починка велосипеда, покупки), встречи (с научным руководителем, знакомыми) и проекты (работа над дипломом, исследование малых LLM). Данный образец поможет оценить работу в условиях малого и специфичного контекста, отличного от текстов статей.

Визуализации ГЗ, созданных на основе этих подкорпусов, изображена на рисунке 5.

3.2.1. Алгоритм генерации связей

Для формирования датасета был написан скрипт для загрузки и обработки статей с использованием `wikipediaapi`, поддерживающий два режима сохранения:

- загрузка заданного набора статей
- обход соседей заданной статьи в ширину с контролем глубины обхода

Во второй стратегии сохранения соседи статьи ранжируются с помощью Cross Encoder модели на основе их краткой сводки и отбирается N наиболее релевантных, что предотвращает уход алгоритма от тематики корневой статьи. Далее алгоритм увеличивает глубину рекурсии и аналогично обрабатывает каждого отобранного соседа до тех пор пока либо не сохранит заданное число статей либо не обойдет все статьи до заданной глубины рекурсии.

Каждая статья, прошедшая проверку Cross Encoder подвергается обработке. В нее входит:

- Нормализация названий файлов, включающая замену пробелов на подчеркивания и удаление некоторых служебных символов для однозначного соответствия названий статей названиям файлов.
- Очистка текста от сносок и маркеров (например, [1]), а также удаление служебных секций статьи, которые не несут содержательной информации для GraphRAG (например, “См. также”, “Литература”, “Ссылки”).
- Формирование специального блока ссылок, извлеченных из графа Википедии, на другие статьи. В данном блоке остаются ссылки только на сохраненные статьи, что решает проблему висячих ссылок.

После сохранения статей начинается этап их ручной доразметки. Этот шаг включает:

- Анализ и фильтрация ссылок, сохраненных из графа Википедии. Все ссылки, для идентификации которых нет контекста в содержимом статьи, удаляются. Например, в статье Билл Гейтс сказано, что он соосновал Microsoft, следовательно связь Билл Гейтс -> (соосновал) Microsoft должна быть оставлена.
- Анализ типов ссылок. Как было упомянуто ранее, в графе Википедии часть ссылок уже типизирована. Эти типы дополняются недостающими, а также абстрагируются для сокращения их общего числа. Критично обеспечить оптимальный уровень абстракции, чтобы не запутать языковая модель: большое количество узких по смыслу ссылок может показаться лучшим решением, но на практике модель начнет выбирать неверные типы, например из-за недостатка контекста.

Для упрощения разметки и алгоритмов все типы отношений фиксируются на английском языке (например, Uses, Part of, Mentions), несмотря на то,

что содержимое некоторых заметок на русском языке.

В каждом подкорпусе присутствует файл `.meta`, в котором содержится список статей с Википедии, на основе которых он был создан, а также список допустимых типов отношений.

Результатом ручной доразметки является блок классифицированных ссылок в каждой статье, оформленный в синтаксисе плагина `Dataview`:

```
## Related Connections:
- Mentions:: [[ASML_Holding]]
- Manufactures:: [[Integrated_circuit]]
- Sustains:: [[Moores_law]]
- Is a:: [[Photolithography]]
```

Подкорпус	# заметок	# ссылок	# типов связей	Ср. исх. ссылок на заметку
hub_n_spoke	15	77	12	5.13
realistic	15	79	12	5.27
versus	15	44	14	2.93
sequence	7	23	7	3.29
personal	11	23	7	2.09
Итого	63	246	—	3.90

Таблица 2 – Сводная статистика по эталонным подкорпусам

В таблице 2 приведена информация о собранных данных. `hub_n_spoke` и `realistic` обладают самым высоким средним числом связей на заметку (в среднем 5.2 исходящих ссылки), то есть в них много семантически близких и связанных сущностей. Они помогают оценить пайплайн построения графа на устойчивость к шуму. `versus`, несмотря на идентичное число заметок, имеет вдвое меньше связей, поскольку в нем часть сущностей не имеют никаких семантических отношений. Аналогичная ситуация в `sequence`: в нем изложена последовательность, в которой каждая сущность в основном связана только с предыдущей и следующей.

Датасеты хранятся в директории `data/test_vaults/gold`.

3.2.2. Алгоритм извлечения контекста

Для оценки retrieval-этапа был создан отдельный датасет, состоящий из фрагментов текстов, в которых явно или косвенно упоминаются сущности и подкорпуса.

В качестве минимального фрагмента текста было решено взять предложение, содержащие упоминание. Это позволит сохранить контекст, а также проверять алгоритм на точность извлечения, то есть долю других предложений, не содержащих упоминание.

Для каждого элемента датасета было проведено ручное извлечение всех фрагментов с упоминаниями. На их основе создан набор JSON-файлов (по одному на элемент эталонного набора данных для оценки алгоритма генерации ссылок), хранящийся в директории `data/test_retrieval/gold`. Каждый файл содержит массив кортежей $(s, e, sent, is_direct)$, где s – файл-источник, e – целевая сущность, $sent$ – предложение, в котором упомянута сущность, is_direct – содержит ли предложение прямое упоминание сущности. Допускается, что для одной пары (s, e) может присутствовать несколько записей с разными извлеченными предложениями.

Важно уточнить, что для соблюдения требований к данным, описанным в главе 1.4, в датасете используются только чанки, содержащие упоминания сущностей, представленных в подкорпусе.

3.2.3. Алгоритм LLM-классификации отношений

Для валидации LLM-классификатора отношений используется дополненная версия описанного выше датасета для оценки retrieval. В каждую запись в JSON-файлах было добавлено поле `link_type`, соответствующее истинному типу отношения. Таким образом финальная структура кортежей имеет следующий вид: $(s, e, sent, is_direct, link_type)$.

Значения `link_type` были взяты из блока ссылок датасета для оценки алгоритма генерации связей. В случае, если сущность упомянута в нескольких

предложениях, каждое из них получает одинаковое значение *link_type*.

Вывод.

Для оценки качества и устойчивости алгоритмов к разным сценариям использования были сформированы датасеты, различающиеся тематикой, плотностью информацией, сложностью и набором сущностей, для оценки как всего пайплайна, так и для конкретных его этапов. Данный подход задуман для упрощения тонкой настройки гиперпараметров и выбора оптимальных стратегий извлечения контекста и классификации связей.

Выбор в пользу Википедии обеспечил выполнение правила “одна заметка = одна сущность” и позволил получить управляемый объем данных с качественным содержимым, достаточным для оценки GraphRAG.

ЭКСПЕРИМЕНТЫ

4.1 Параметры воспроизводимости

Для обеспечения воспроизводимости экспериментов был зафиксирован сид генерации (seed) на значении равным 42. Также во всех экспериментах с LLM (как при классификации связей, так и при генерации ответов) температура генерации (temperature) равнялась 0, параметр top_p был равным 0.1. Такие значения позволяют минимизировать стохастичность и ”креативность» моделей, заставляя их генерировать предсказуемые ответы, основываясь на предоставленном контексте.

4.2 Оценка конвейера построения графа знаний

4.2.1. Извлечение кандидатных пар

Извлечение может быть осуществлено тремя способами: strict, broad и combined. Подробное описание этих стратегий приведено в главе 2.1.

Стратегия Strict.

В таблице 3 приведены результаты работы стратегии Strict на валидационном датасете для алгоритмов извлечения.

Precision	Recall	F ₁	Время, с
1.0	0.376	0.547	206

Таблица 3 – Результат Strict на валидационном датасете

Список извлеченных фрагментов не содержит ложноположительных результатов, что обеспечивает идеальную точность. Однако такой подход ограничен по полноте, так как он не способен извлечь чанки, в которых искомая сущность не упомянута явно. Таким образом, strict подход задает верхнюю границу по точности и нижнюю по полноте. Стоит отметить, что эта стратегия извлекла все прямые упоминаний сущностей, что было достигнуто путем лемматизации текстов.

Общее время работы стратегии на всем датасете составило 206 секунд, что около 41 секунды на подкорпус в среднем. Кроме того, лемматизация текста заняла около 194 секунд, а сам поиск – оставшиеся 12 секунд.

Стратегия Broad.

Качество работы данной стратегии зависит от значений параметров, а также используемых моделей, поэтому для достижения наилучшего качества извлечения был проведен ряд экспериментов.

Первоначальные настройки указаны в таблице 4. Их выбор был основан на значениях, используемых в референсных решениях ObsidianRAG [25] и neo4j Graph Builder [9], а также на структуре валидационного датасета. Поскольку в нем используются markdown-файлы, имеет смысл приоритезировать разбиение текста на основе заголовков. Модели выбраны на основе их метрик и популярности на HuggingFace.

Параметр	Значение
Эмбединги и разбиение текста	
Модель эмбедингов	paraphrase-multilingual-MiniLM-L12-v2 [30]
Размер чанка	4000
Перекрытие чанков	200
Разделители	["\n# ", "\n## ", "\n### ", "\n\n", ". ", "? ", "! ", "\n", " ", ""]
Поиск	
Топ-К	15
Вес векторного поиска	0.5
Переранжирование	
Модель	BAAI/bge-reranker-v2-m3 [31]
Топ-К	5
Порог	0.7

Таблица 4 – Изначальные гиперпараметры алгоритма извлечения

Для поиска оптимальной конфигурации был проведен ряд экспериментов, заключающихся в смене размера чанка, моделей эмбедингов и

переранжирования. Их результаты представлены в таблице 5.

Поскольку стратегия *Strict* уже обеспечивает идеальную точность, основной идеей экспериментов над *Broad* было увеличение полноты при сохранении приемлемой точности. Допустимый порог *Precision* был сделан равным 0.5. Его достижение будет первостепенной задачей, после чего приоритет сместится на максимизацию полноты при сохранении точности выше порога.

#	CS	CO	E	К	CE	Порог	P	R	F ₁	Время
1	4000	200	MiniLM [30]	15	bge-r [31]	0.7	0.354	0.199	0.255	34
2	3000	200	MiniLM	15	bge-r	0.7	0.395	0.190	0.256	40
3	5000	300	MiniLM	15	bge-r	0.7	0.301	0.186	0.223	27
4	3000	200	MiniLM	15	jina [32]	0.7	0.553	0.208	0.302	9
5	3000	200	MiniLM	15	jina	0.5	0.510	0.407	0.452	9
6	3000	200	MiniLM	30	jina	0.5	0.500	0.453	0.475	20
7	3000	200	bge-e [33]	30	jina	0.5	0.531	0.468	0.498	23
<i>Strict (базис)</i>							1.0	0.376	0.547	3.4

Примечание: Используемые модели:

MiniLM – paraphrase-multilingual-MiniLM-L12-v2,

bge-e – BAAI/bge-m3,

bge-r – BAAI/bge-reranker-v2-m3,

jina – jina-reranker-v2-base-multilingual.

CS – Chunk Size, CO – Chunk Overlap, E – Embedding Model, CE – Cross Encoder,

Порог – минимально допустимая оценка CE, время в минутах

Таблица 5 – Анализ конфигураций стратегии *Broad*.

Влияние размера чанка. Эксперименты 1-3 показали, что фрагмент текста не может быть слишком большим, так как это приводит к потере деталей, что негативно сказывается на точности поиска. Оптимальным по качеству вариантом оказался размер в 3000 символов с перекрытием в 200 символом.

Стоит отметить влияние размера чанков на время работы. Уменьшение размера чанка ведет к увеличению числа фрагментов, которые нужно перевести в векторное пространство, из-за чего растет количество пар для сравнения, и следовательно время работы. Поэтому возникает компромисс: увеличить размер чанков, сделав их менее детализированными, но снизив время работы, либо уменьшить размер, увеличив время.

Роль модели переранжирования. Модель Cross Encoder также оказалась

крайне важной. Переход с bge-r на jina увеличил F_1 до 0.302 (эксперимент 4), но потребовал снижения порога с 0.7 до 0.5 для раскрытия потенциала модели (эксперимент 5). Как итог, F_1 вырос до 0.452.

Изначальное значение порога оценки Cross Encoder для фильтрации результатов было завышенным, из-за чего часть истинно положительных кандидатов отбрасывалась. При bge-r порог в 0.7 был оправдан, так как модель имела низкую точность, но использование jina решило эту проблему, повысив значение Precision с 0.395 до 0.553.

Смена модели также значительно сократила время работы алгоритма (с 40 до 9 минут). Это объясняется вдвое меньшим количеством параметров в модели jina (300 миллионов против 600 у bge-r), использованием BF16 вместо F32 у bge-r, а также более современной и вычислительно эффективной архитектурой.

Так как первостепенная цель экспериментов достигнута (порог превысил 0.5), последующие опыты будут нацелены на максимизацию полноты при сохранении приемлемой точности.

Количество извлекаемых чанков. С ростом точности извлечения и значительным сокращением времени работы появился смысл увеличить число извлекаемых кандидатов при гибридном поиске (Top-K). Снижение его значения не имеет особого смысла, так как это скорее всего сильно снизит полноту, что противоречит цели.

По результатам эксперимента 6 видно, что увеличение Top-K спровоцировало рост шума, а также времени работы, но увеличило полноту.

Смена модели эмбедингов. На замену MiniLM, переводящую тексты в 384-мерное пространство пришла более тяжелая bge-m3, которая работает с 1024-мерными эмбедингами. Идея была в улучшении сохранения детализации смыслов в текстах. Как итог, рост точности и полноты на 0.031 и 0.015 соответственно по сравнению с результатами эксперимента 6.

Стратегия Combined.

В данной стратегии использовалась оптимальная конфигурация Broad. Результаты представлены в таблице 6. Видно, что Broad вносит весомый вклад: полнота выросла практически вдвое (с 0.376 до 0.685), но ожидаемо упала точность (с 1 до 0.675). Полученные результаты подтверждают теорию: данная стратегия действительно является компромиссом между высокой точностью и полнотой.

Precision	Recall	F_1
0.675	0.685	0.680

Таблица 6 – Результат Combined на валидационном датасете




Рис. 4 – Динамика F_1 стратегии Broad по экспериментам. Красная пунктирная линия — уровень Strict-стратегии. Квадрат — результат Combined для лучшей конфигурации.

4.2.2. Классификация типов связей

В рамках данной серии экспериментов рассматривалась способность больших языковых моделей корректно определять семантический тип связи между сущностями на основе собранных контекстов. Для оценки использовался в ручную размеченный валидационный датасет.

Поскольку важна как точность, так и полнота классификации, в качестве основной метрики был выбран F_1 -score. Кроме того, так как в данных

присутствует дисбаланс, уместнее всего использовать Weighted F_1 . Идея экспериментов заключалась в максимизации основной метрики путем поиска оптимального промпта, размера батча и модели.

Модель	Промпт	Batch	P	H	R	S	V	W. F_1
Gemma-3-27B [34]	base	1	0.346	0.340	0.351	0.459	0.522	0.393
Gemma-3-27B	base	5	0.446	0.325	0.321	0.451	0.573	0.387
Gemma-3-27B	base	10	0.378	0.428	0.363	0.392	0.572	0.423
Qwen-3-235B	base	1	0.313	0.454	0.272	0.454	0.526	0.392
Gemma-3-27B	few-shot	1	0.372	0.436	0.444	0.341	0.559	0.445
Qwen-3-235B [35]	few-shot	1	0.498	0.390	0.434	0.558	0.482	0.445
Gemma-4-31B[36]	few-shot	1	0.856	0.578	0.627	0.786	0.758	0.669

Примечание: Используемые промпты доступны в репозитории проекта по пути: `artifacts/prompts/classification`.

Таблица 7 – Weighted F_1 классификации типов связей

Результаты опытов представлены в таблице 7.

Влияние батчинга. Увеличение размера батча (количества пар заметок, передаваемых модели за один запрос) в среднем снижает среднюю оценку, однако в некоторых случаях она растет. Увеличение может быть вызвано утечкой контекста: модель получает дополнительные данные из других элементов батча. Это видно в случае Personal, Hub-n-Spoke и Versus, где размер содержимого заметок мал, и есть кластеры из тематически связанных заметок. Тем не менее, важно не перегрузить модель лишним контекстом: при классификации конкретной связи контекст для других считается шумом и не должен быть учтен. Не все модели могут корректно разграничить содержимое, из-за чего начинают путаться и делать ошибочные выводы, ухудшая качество классификации. Как наиболее честный вариант был выбран размер батча равный 1.

Влияние промпта. Добавление в промпт примеров и описаний типов связей, которые в них используются увеличило значение Overall F_1 как для Gemma-3-27B с 0.392 до 0.423 (+0.031), так и для Qwen-3-235B с 0.392 до 0.445 (+0.135). Это подтверждает чувствительность моделей к инструкциям и примерам: они помогают им лучше понять специфику задачи и не уйти

в сторону при рассуждении. Важно точно определить каждый тип связи для устранения неоднозначностей. Кроме того, результаты показывают, что качество более крупной модели больше зависит от промпта.

Влияние выбора модели. Эксперименты показали, что эффективность архитектуры важнее числа параметров. Новая Gemma-4-31B (31 млрд параметров) значительно превосходит по качеству Qwen-3-235B (235 млрд параметров), а Gemma-3-27B (27 млрд параметров) оказалась в ней наравне.

Анализ ошибок классификации. Несмотря на рост общего значения Weighted F_1 , имеется несколько общих ошибок:

- **Злоупотребление универсальными типами.** Тип `mentions` является самым популярным в датасете (40 связей, $F_1 = 0.23\text{--}0.39$). Он играет роль резервного класса: он назначается в случае, когда связь есть, но невозможно однозначно назначить другой класс. Модель может слишком часто назначать этот тип из-за его универсальности. Эта проблема решается дополнительными инструкциями и примерами в промпте, явно указывающими смысл этой связи.
- **Использование близких по смыслу связей.** Классы `encompasses`, `contains`, `incorporates` и другие имеют высокое семантическое сходство. Большое их количество создает путаницу: модель не способна выявить семантической разницы между ними, поэтому с высокой вероятностью может использовать неверный тип. Проблема обостряется в реальных условиях неточного контекста, который создает алгоритм извлечения контекста. Эффективным решением будет объединение подобных классов в один более универсальный.

4.3 Сравнение сгенерированных ссылок с эталонными

Перед оценкой GraphRAG на сгенерированных ссылках необходимо их проанализировать. Оценка проводилась в двух режимах: без учета типа (оценивается только факт наличия связи между заметками) и с учетом типа

(оценивается как наличие связи, так и правильность предсказанного типа) для анализа качества ссылок для использования в каждой типе обхода. Использовались лучшие конфигурации извлечения (стратегия Combined) и типизации (Gemma-4-31B, few-shot промпт, $batch = 1$).

Подкорпус	Без учета типа (Untyped)			С учетом типа (Typed)		
	P	R	F ₁	P	R	F ₁
hub_n_spoke	0.810	0.883	0.845	0.643	0.701	0.671
personal	0.909	0.435	0.588	0.909	0.435	0.588
realistic	0.771	0.810	0.790	0.687	0.722	0.704
sequence	0.733	0.957	0.830	0.533	0.696	0.604
versus	0.727	0.909	0.808	0.545	0.682	0.606
Взвеш. усред.	0.776	0.829	0.802	0.635	0.679	0.656

Таблица 8 – Оценка качества сгенерированных связей: факт наличия (Untyped) и точное совпадение типа (Typed)

Точность извлеченных ссылок без учета их типа находится на высоком уровне: $F_1 = 0.802$, при этом полнота также имеет близкое к идеальному значение $R = 0.829$, что говорит о способности алгоритма находить практически все ссылки. Наилучшие результаты наблюдаются в подкорпусах *sequence* ($R = 0.957$) и *versus* ($R = 0.909$).

Введение типов ссылок как критерия оценивания снизило значения метрик: F_1 упал до 0.656. Исключением является образец *personal*, в котором метрики не изменились. Это означает, что алгоритм безошибочно классифицировал все связи. Такой результат был ожидаем, он напрямую коррелирует с результатами главы 4.2.2.

4.4 Оценка конвейера GraphRAG

В таблице 9 представлены первоначальные параметры алгоритмов. Они выбраны на основе количества валидационных данных и референсного решения. Значения подобраны так, чтобы заставить алгоритмы обходить граф, а не собирать контекст всех заметок разом.

Описание параметра	Переменная	Значение
Максимальная глубина обхода графа	MAX_HOPS	2
Ширина Beam Search	BEAM_WIDTH	4
Порог отсеечения узлов по релевантности	SCORE_THRESHOLD	0.2
Количество первоначальных заметок	TOP_K_SEED	3
Итоговое количество чанков в контексте	TOP_K_CONTEXT	10

Таблица 9 – Значения гиперпараметров алгоритма GraphRAG по умолчанию

4.4.1. Анализ референсных решений

Для оценки разработанных алгоритмов было проведено их комплексное сравнение с ObsidianRAG и neo4j (Graph Builder и их же интегрированная реализация RAG). В качестве модели для генерации ответов была выбрана Gemma-3-27B, для оценки Gemma-4-31B.

Подкорпус	CR	CP	F	AC
hub_n_spoke	0.802	0.701	0.955	0.542
personal	0.625	0.615	1.000	0.424
realistic	0.886	0.707	0.898	0.505
sequence	1.000	0.824	0.967	0.582
versus	0.617	0.467	0.883	0.428
Среднее	0.786	0.663	0.941	0.496

Таблица 10 – Результаты решения ObsidianRAG

Результаты оценки референсного решения ObsidianRAG приведены в таблице 10. Явно видны недостатки логики расширения контекста: в `personal` и `versus` наблюдается низкий CR (0.625 и 0.617 соответственно). В этих образцах есть два кластера, которые практически друг с другом не связаны. Наивный сбор контекста соседних узлов не позволит получить информацию из другого кластера, а лишь увеличит шум, что видно по низким значениям CP (0.467 в случае `versus` и 0.615 в случае `personal`). В других образцах, где заметки связаны большим числом ссылок, CR не ниже 0.8, а CP не ниже 0.7, что говорит о хорошей работе алгоритма.

Как результат, следует и низкий AC: контекст зашумлен и в нем недостаточно данных для предоставления полного и точного ответа.

Подкорпус	CR	CP	F	AC
hub_n_spoke	1.000	0.782	0.951	0.598
personal	1.000	0.875	0.984	0.612
realistic	0.985	0.842	0.975	0.620
sequence	0.980	0.855	0.971	0.640
versus	0.920	0.751	0.905	0.540
Среднее	0.977	0.821	0.957	0.602

Таблица 11 – Результаты решения neo4j на сгенерированном ГЗ

В таблице 11 представлены результаты neo4j. Данные значения получены на сгенерированном neo4j Graph Builder ГЗ.

Решение имеет значительно более высокие значения CR, что обусловлено более продвинутой логикой сбора контекста. Среднее значение CR достигло 0.977, в то время как у ObsidianRAG оно лишь 0.786. Также виден большой прирост метрики на подкорпусах `personal` (с 0.625 до 1.000) и `versus` (с 0.617 до 0.920).

Кроме того, CP также вырос – в среднем 0.821 против 0.663 у ObsidianRAG. Это говорит об отличной способности neo4j фильтровать контекст.

Как следствие, увеличились значения AC: среднее значение выросло на 0.106 балла (с 0.496 до 0.602). Прирост особенно заметен на проблемных для ObsidianRAG подкорпусах `personal` (+0.188) и `versus` (+0.112).

Во всех случаях наблюдается высокий Answer Faithfulness: модель не пытается додумать ответ, а использует приведенные данные.

4.4.2. Сравнение собственных алгоритмов с аналогами

Поскольку основным преимуществом алгоритмов, представленных в данной работе, является многошаговый обход, основная цель которого увеличение CR, имеет смысл сфокусироваться только на полноте контекста и качестве ответа при сравнении разработанных алгоритмов с эталонным. Сравнение представлено в таблице 12.

Подкорпус	Данные	Ref		Base		Typed		neo4j	
		CR	AC	CR	AC	CR	AC	CR	AC
hub	GT	0.802	0.542	1.000	0.587	0.958	0.565	—	—
	GEN	0.750	0.516	0.958	0.535	0.958	0.561	1.000	0.598
personal	GT	0.625	0.424	1.000	0.597	1.000	0.579	—	—
	GEN	0.625	0.429	1.000	0.602	1.000	0.642	1.000	0.612
realistic	GT	0.886	0.505	0.977	0.606	0.977	0.601	—	—
	GEN	0.864	0.522	0.977	0.637	0.977	0.602	0.985	0.620
sequence	GT	1.000	0.582	0.925	0.580	0.975	0.631	—	—
	GEN	0.975	0.555	0.925	0.614	0.925	0.600	0.980	0.640
versus	GT	0.617	0.428	0.900	0.524	0.788	0.507	—	—
	GEN	0.608	0.388	0.900	0.550	0.788	0.520	0.920	0.540
Среднее	GT	0.786	0.496	0.960	0.579	0.940	0.577	—	—
	GEN	0.764	0.482	0.952	0.587	0.930	0.585	0.977	0.602

Таблица 12 – Сравнение собственных алгоритмов с аналогами на размеченном (GT) и сгенерированном (GEN) графах.

Оценка GraphRAG на размеченных данных

Видно, что модифицированная логика обхода действительно увеличила количество собираемой информации по сравнению с ObsidianRAG, позволив получить практически идеальную полноту контекста. Это оказалось особенно заметно в случае `personal` и `versus`, где изначально значение CR было самым низким. В их случае прирост составил 0.375 и 0.283 соответственно в случае Base, 0.375 и 0.171 в случае Typed.

Дополнительный контекст помог языковой модели дать более точный ответ, что также увеличило средние значение AC с 0.496 до 0.579 (Base) и 0.577 (Typed)

Оценка GraphRAG на сгенерированном графе

Для получения первоначальных данных и оценки качества работы алгоритмов на автоматически построенных ГЗ в следующем эксперименте размеченный ГЗ был заменен на граф, построенным пайплайном генерации связей. Результаты приведены в таблице 12.

Видно, что замена графа минимально влияет на качество работы

GraphRAG: значения метрик колеблются в диапазоне сотых долей.

Переход на сгенерированные связи незначительно снизил CR: для базового алгоритма среднее значение упало с 0.960 до 0.952, а для типизированного — с 0.940 до 0.930. Это падение можно объяснить пропуском неочевидных связей конвейером построения ГЗ, из-за чего усложняется навигация по графу.

Интересным наблюдением является рост AC (с 0.579 до 0.587 для Base и с 0.577 до 0.585 для Typed). Особенно заметно увеличение в подкорпусе `personal` для Typed-обхода (с 0.579 до 0.642) и в `realistic` для Base-обхода (с 0.606 до 0.637). Возможно, что сгенерированные связи в некоторых случаях более эффективны для сбора релевантного контекста, так как пайплайн мог иначе типизировать связи или создать новые, которые помогли извлечь нужные данные.

Алгоритм Base показал себя лучше в большинстве случаев как при сборе контекста, так и генерации ответов.

Результаты работы предложенных алгоритмов оказались сопоставимы с `neo4j`: в среднем алгоритм Base уступает ему всего на 0.025 по полноте и на 0.015 по точности ответа, алгоритм Typed на 0.047 и 0.017 соответственно. Это доказывает эффективность разработанных алгоритмов.

4.4.3. Влияние промпта и языковой модели

Для исследования влияния различных факторов и компонент GraphRAG на качество ответа LLM была проведена серия экспериментов над решениями, представленными в данной работе. Все замеры проводились на размеченных данных.

Базовый промпт против few-shot.

На основе экспериментов над LLM-классификацией связей был сделан вывод о важности указания точных инструкций и конкретных примеров в промпте. В базовом промпте уже есть основные указания, такие как придерживание предоставленного контекста и ответ на языке запроса. К ним

были добавлены конкретные развернутые примеры и требования модели к рассуждениям перед ответом. Модели для оценки и генерации остались теми же.

Алгоритм	Промпт	H	P	R	S	V	AC avg
Base	Базовый	0.587	0.597	0.606	0.580	0.524	0.579
	Few-shot	0.595	0.572	0.604	0.618	0.569	0.592
Typed	Базовый	0.565	0.579	0.601	0.631	0.507	0.577
	Few-shot	0.600	0.611	0.606	0.629	0.555	0.580

Примечание: Используемые промпты доступны в репозитории проекта по пути: `artifacts/prompts/graphrag`.

Таблица 13 – Сравнение базового и few-shot промптов на алгоритмах Base и Typed (метрика AC, модель Gemma-3-27B)

Новый промпт продемонстрировал прирост AC в среднем лишь +0.13. Прирост оказался ниже, чем в предыдущих сравнениях, вероятно, из-за корректно сформулированных инструкций в базовом промпте. Можно сделать вывод, что наличие примеров все же дает небольшой прирост корректности ответа языковой модели.

Анализ влияния языковой модели.

В этом эксперименте модель для генерации будет заменена на Gemma-4-31B, а моделью-судьей будет Gemini-3-flash [37].

Датасет	Алгоритм	Эксп. 2 (Gemma-3-27B)			Эксп. 3 (Gemma-4-31B)		
		CP	CR	AC	CP	CR	AC
hub	Base	0.749	1.000	0.595	0.660 ↓	0.875 ↓	0.698 ↑
	Typed	0.796	0.958	0.600	0.707 ↓	0.833 ↓	0.709 ↑
personal	Base	0.893	1.000	0.572	0.750 ↓	1.000 =	0.796 ↑
	Typed	0.892	1.000	0.611	0.729 ↓	0.917 ↓	0.770 ↑
realistic	Base	0.848	0.977	0.604	0.426 ↓	1.000 ↑	0.738 ↑
	Typed	0.851	0.977	0.606	0.491 ↓	0.955 ↓	0.792 ↑
sequence	Base	0.879	0.925	0.618	0.434 ↓	0.765 ↓	0.734 ↑
	Typed	0.878	0.975	0.629	0.429 ↓	0.765 ↓	0.706 ↑
versus	Base	0.734	0.900	0.569	0.519 ↓	0.655 ↓	0.623 ↑
	Typed	0.696	0.813	0.555	0.547 ↓	0.568 ↓	0.576 ↑
Среднее	Base	0.821	0.960	0.592	0.558 ↓	0.859 ↓	0.718 ↑
	Typed	0.823	0.945	0.600	0.581 ↓	0.808 ↓	0.711 ↑

Таблица 14 – Сравнение моделей Gemma-3-27B и Gemma-4-31B (few-shot промпт)

Результаты представлены в таблице 14. Прирост AC составил в среднем +0.128, при этом CP упал в среднем на -0.263. Сильнее всего CP снизился на realistic (с 0.848 до 0.426) и sequence (с 0.879 до 0.434). Снижение CP обусловлено более строгой оценкой модели. Однако рост AC показывает, что более мощная модель для генерации ответов способна абстрагироваться от шума и дать более точный ответ.

Сравнение типизированного обхода с обычным.

У типизированного обхода выше CP (среднее: 0.581 против 0.558 у Base), но ниже CR (0.808 против 0.859 у Base). Эти результаты показывают влияние фильтрации заметок при обходе графа: тематически нерелевантные файлы отсекаются, но при этом также теряется возможность сделать дополнительный шаг через этот файл, чтобы оценить его соседей, из-за чего упускается часть информации.

При этом нельзя сделать однозначный вывод о влиянии учета типов ссылок на корректность ответов. В плотно связанных подкорпусах, таких как realistic, типизированный подход обладает большей точностью контекста,

но на разреженных графах доминирует обычный обход, видимо, потому что он позволяет делать дополнительные шаги через нерелевантные узлы, что иногда позволяет добраться до необходимой информации.

4.4.4. Анализ влияния графа.

Результаты в таблице 15 уже показали устойчивость и эффективность сгенерированных ссылок. Данный эксперимент нацелен подтвердить, что этот результат сохраняется при использовании более мощных и строгих LLM как для генерации ответа, так и для оценки.

Датасет	Алгоритм	Разметка			Сгенерированные		
		CP	CR	AC	CP	CR	AC
hub	Base	0.660	0.875	0.698	0.689 ↑	0.833 ↓	0.682 ↓
	Typed	0.707	0.833	0.709	0.707 =	0.833 =	0.716 ↑
personal	Base	0.750	1.000	0.796	0.729 ↓	0.958 ↓	0.762 ↓
	Typed	0.729	0.917	0.770	0.729 =	0.917 =	0.770 =
realistic	Base	0.426	1.000	0.738	0.426 =	1.000 =	0.738 =
	Typed	0.491	0.954	0.792	0.476 ↓	0.977 ↑	0.774 ↓
sequence	Base	0.434	0.765	0.734	0.434 =	0.765 =	0.734 =
	Typed	0.429	0.765	0.706	0.429 =	0.765 =	0.706 =
versus	Base	0.519	0.655	0.623	0.519 =	0.655 =	0.623 =
	Typed	0.547	0.568	0.576	0.547 =	0.568 =	0.576 =
Среднее	Base	0.558	0.859	0.718	0.559 ↑	0.842 ↓	0.708 ↓
	Typed	0.581	0.807	0.711	0.578 ↓	0.812 ↑	0.708 ↓

Таблица 15 – Сравнение качества работы GraphRAG между размеченным графом и сгенерированным.

На основе полученных результатов (таблица 15) можно сделать вывод, что использование сгенерированных связей практически не влияет на качество работы GraphRAG.

Падение метрики AC при переходе на автоматически построенный граф в среднем не превышает 0.01 (с 0.718 до 0.708 для Base-обхода и с 0.711 до 0.708 для Typed-обхода). Самое большое падение AC наблюдается в случае базового алгоритма в образце `personal` и составляет 0.034 (с 0.796 до 0.762).

Колебание значений Context Precision и Context Recall незначительны, что

говорит о сопоставимом качестве связей с ручной разметкой. Эти результаты говорят об высокой устойчивости к шуму алгоритма построения ГЗ.

4.5 Выводы и ограничения исследования

Опыты над алгоритмом конструирования графа определили оптимальную конфигурацию извлечения контекста: переход к рекурсивному алгоритму вместе с использованием Jina как модели переранжирования позволил достичь $F_1 = 0.498$, что в комбинации с результатами стратегии Strict дает оптимальный баланс между точностью и полнотой извлеченных фрагментов.

Эксперименты над LLM-классификацией связи доказали критичность использования few-shot промпта с четкими инструкциями, а также важность современной архитектуры языковой модели: Gemma-4-31B показала результат Overall $F_1 = 0.669$, превзойдя более крупную Qwen-3-235B ($F_1 = 0.445$). Также важным оказалось объединение семантически схожих классов ссылок для упрощения классификации языковой моделью.

Оценка предложенных алгоритмов GraphRAG через RAGAS показала их эффективность: по результатам видно явное превосходство над ObsidianRAG и сопоставимое с neo4j качество работы. Разработанная логика сбора контекста повысила CR по всех подкорпусах вплоть до 1.0. Сравнение типизированного обхода с обычным показало гибкость системы: алгоритм может точно извлекать достаточный объем информации в разных сценариях. Типизированный обход лучше всего подходит для работы с шумными, плотно связанными графами. Базовый, в свою очередь, демонстрирует отличные результаты на разреженных графах, требующих многошаговое извлечение контекста.

Финальное сравнение работы предложенных алгоритмов GraphRAG на сгенерированных ссылках показало высокое качество пайплайна для построения графов знаний в Obsidian. Конвейер устойчив к шуму и может справляться с неоднозначными и сложными ситуациями.

Важно отметить, что во всех экспериментах значения метрики Answer Faithfulness были не ниже 0.88, что говорит об отсутствии галлюцинаций и

использовании языковыми моделями приведенного контекста.

Несмотря на все достижения, у проведенного исследования есть ряд ограничений:

- *Размер и однотипность тестовых данных.* Датасет содержит всего 5 подкорпусов, которые вместе насчитывают 63 заметки и 246 ссылок (таблица 2). Их содержимое в основном – статьи Википедии. Этого сильно ограничивает значимость метрик и делает невозможным оценку масштабируемости предложенных подходов и эксперименты с гиперпараметрами GraphRAG.
- *Ограниченность онтологии.* Набор используемых данных содержит всего несколько схожих тематических групп. Исходя из этого, невозможно предположить поведение системы на данных из другой области.
- *Зависимость от качества разметки.* Валидационных датасет создавался одним человеком, что вносит долю субъективности в типы некоторых связей.

ЗАКЛЮЧЕНИЕ

СПИСОК ЛИТЕРАТУРЫ

На английском языке

- [1] *Ahrens S.* How to Take Smart Notes: One Simple Technique to Boost Writing, Learning and Thinking. — CreateSpace Independent Publishing Platform, 2017.
- [2] *Dynalist Inc.* Obsidian: A knowledge base that works on local Markdown files [Электронный ресурс]. — Режим доступа: [https : / / obsidian . md/](https://obsidian.md/) (дата обращения: 09.05.2026).
- [3] *Forte T.* Building a second brain: A proven method to organize your digital life and unlock your creative potential. — 2022.
- [4] Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks / P. Lewis [и др.] // *Advances in Neural Information Processing Systems*. Т. 33. — 2020. — С. 9459—9474.
- [5] *Robertson S., Zaragoza H.* The Probabilistic Relevance Framework: BM25 and Beyond // *Foundations and Trends in Information Retrieval*. — 2009. — Т. 3, № 4. — С. 333—389.
- [6] Dense Passage Retrieval for Open-Domain Question Answering / V. Karpukhin [и др.] // *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. — 2020. — С. 6769—6781.
- [7] Retrieval-Augmented Generation for Large Language Models: A Survey / Y. Gao [и др.] // *arXiv preprint arXiv:2312.10997*. — 2023.
- [8] From Local to Global: A Graph RAG Approach to Query-Focused Summarization / D. Edge [и др.] // *arXiv preprint arXiv:2404.16130*. — 2024.
- [9] *Neo4j Labs.* LLM Graph Builder [Электронный ресурс]. — 2026. — Режим доступа: <https://github.com/neo4j-labs/llm-graph-builder> (дата обращения: 06.05.2026).

- [10] *Memgraph*. Unstructured2Graph [Электронный ресурс]. — 2026. — Режим доступа: <https://github.com/memgraph/ai-toolkit/tree/main/unstructured2graph> (дата обращения: 06.05.2026).
- [11] *Mem Labs*. Mem.ai: The self-organizing workspace. — Режим доступа: <https://mem.ai/> (дата обращения: 08.05.2026).
- [12] A Survey of Large Language Models / W. X. Zhao [и др.] // arXiv preprint. — 2023. — arXiv: 2303.18223.
- [13] Survey of hallucination in natural language generation / Z. Ji [и др.] // ACM Computing Surveys. — 2023. — Т. 55, № 12. — С. 1—38.
- [14] *Nogueira R., Cho K.* Passage Re-ranking with BERT // arXiv preprint. — 2019. — arXiv: 1901.04085.
- [15] *Chase H.* LangChain. — Режим доступа: <https://github.com/langchain-ai/langchain> (дата обращения: 25.02.2026).
- [16] An optimized pipeline for automatic educational knowledge graph construction [Электронный ресурс] / Q. U. Ain [и др.] // arXiv preprint arXiv:2509.05392. — 2025. — DOI: 10.48550/arXiv.2509.05392.
- [17] SqueezeBERT: What can computer vision teach NLP about efficient neural networks? / F. Iandola [и др.] // arXiv preprint. — 2020. — arXiv: 2006.11316.
- [18] *Reimers N., Gurevych I.* Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks // Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP). — 2019. — С. 3982—3992.
- [19] *Smart Connections*. Smart Connections Plugin for Obsidian [Электронный ресурс]. — Режим доступа: <https://smartconnections.app/> (дата обращения: 06.05.2026).
- [20] *SkepticMystic*. Graph Analysis for Obsidian [Электронный ресурс]. — 2024. — Режим доступа: <https://github.com/SkepticMystic/graph-analysis> (дата обращения: 06.05.2026).

- [21] *Manning C. D., Raghavan P., Schütze H.* Introduction to Information Retrieval. — Cambridge University Press, 2008.
- [22] RAGAS: Automated evaluation of retrieval augmented generation / S. Es [и др.] // arXiv preprint. — 2023. — arXiv: 2309.15217.
- [23] *LanceDB.* LanceDB: Developer-friendly, serverless vector database. — Режим доступа: <https://lancedb.com/> (дата обращения: 25.02.2026).
- [24] *Gerganov G.* llama.cpp: Port of Facebook's LLaMA model in C/C++. — 2026. — Режим доступа: <https://github.com/ggerganov/llama.cpp> (дата обращения: 25.02.2026).
- [25] *Vasallo94.* ObsidianRAG: A Retrieval-Augmented Generation pipeline for Obsidian [Электронный ресурс]. — 2024. — Режим доступа: <https://github.com/Vasallo94/ObsidianRAG> (дата обращения: 06.05.2026).
- [26] *noodleslove.* Personal Notes Repository [Электронный ресурс]. — 2026. — Режим доступа: <https://github.com/noodleslove/notes> (дата обращения: 06.05.2026).
- [27] *Hundred Rabbits.* 100r.co Source Code and Documentation [Электронный ресурс]. — 2026. — Режим доступа: <https://github.com/hundredrabbits/100r.co> (дата обращения: 06.05.2026).
- [28] *Smith L.* based.cooking [Электронный ресурс]. — 2026. — Режим доступа: <https://github.com/luke-smithxyz/based.cooking> (дата обращения: 06.05.2026).
- [29] *Akbary K.* Learning Notes [Электронный ресурс]. — 2026. — Режим доступа: <https://github.com/keyvanakbary/learning-notes> (дата обращения: 06.05.2026).
- [30] *Sentence Transformers.* paraphrase-multilingual-MiniLM-L12-v2 [Электронный ресурс]. — 2026. — Режим доступа: <https://huggingface.co/cross-encoder/mmarco-mMiniLMv2-L12-H384-v1> (дата обращения: 06.05.2026).


- [31] *Beijing Academy of Artificial Intelligence (BAAI)*. bge-reranker-v2-m3 [Электронный ресурс]. — 2026. — Режим доступа: <https://huggingface.co/BAAI/bge-reranker-v2-m3> (дата обращения: 06.05.2026).
- [32] *Jina AI*. jina-reranker-v2-base-multilingual [Электронный ресурс]. — 2026. — Режим доступа: <https://huggingface.co/jinaai/jina-reranker-v2-base-multilingual> (дата обращения: 06.05.2026).
- [33] *Beijing Academy of Artificial Intelligence (BAAI)*. BGE-M3 [Электронный ресурс]. — 2026. — Режим доступа: <https://huggingface.co/BAAI/bge-m3> (дата обращения: 06.05.2026).
- [34] *Google DeepMind*. Gemma 3 27B: Open Models Based on Gemini Research and Technology [Электронный ресурс]. — 2026. — Режим доступа: <https://huggingface.co/google/gemma-3-27b-it> (дата обращения: 06.05.2026).
- [35] *Alibaba Cloud*. Qwen 3 235B Instruct [Электронный ресурс]. — 2026. — Режим доступа: <https://huggingface.co/Qwen/Qwen3-235B-A22B-Instruct-2507> (дата обращения: 06.05.2026).
- [36] *Google DeepMind*. Gemma 4 31B: Advanced Open Models [Электронный ресурс]. — 2026. — Режим доступа: <https://huggingface.co/google/gemma-4-31b> (дата обращения: 06.05.2026).
- [37] *Google DeepMind*. Gemini 3 Flash: Fast and versatile multimodal model [Электронный ресурс]. — 2026. — Режим доступа: <https://ai.google.dev/gemini-api/docs/models/gemini> (дата обращения: 06.05.2026).

ПРИЛОЖЕНИЕ А


7.1 Репозиторий с кодом:

https://github.com/conk7/knowledge_graph_builder


7.2 Визуализации подкорпусов датасета




(a) Подкорпус Hub-and-Spoke




(b) Подкорпус Realistic



(c) Подкорпус Versus



(d) Подкорпус Sequence



(e) Подкорпус Personal

Рис. 5 – Визуальные представления семантических графов подкорпусов датасета